

Spark

Você foi contratado para integrar a equipe de análise de dados de uma grande empresa multinacional. Nessa equipe, é utilizada a tecnologia Spark para processar grandes bases de dados utilizando a linguagem de programação Python. No projeto atual, você deverá utilizar o framework Spark para extrair uma série de informações sobre transações comerciais internacionais realizadas pela empresa nos últimos 30 anos. Essas transações estão armazenadas em um dataset estruturado com 10 colunas, conforme a descrição apresentada na tabela abaixo:

Variable (column)	Description
Country	Country involved in the commercial transaction
Year	Year in which the transaction took place
Commodity code	Commodity identifier
Commodity	Commodity description
Flow	Flow, e.g. Export or Import
Price	Price, in USD
Weight	Commodity weight
Unit	Unit in which the commodity is measured, e.g. Number of items
Amount	Commodity amount given in the aforementioned unit
Category	Commodity category, e.g. <i>Live animals</i>

O dataset contém mais 8 milhões de exemplos (ou seja, 8 milhões de linhas que representam as transações comerciais da empresa). Esse dataset é disponibilizado no formato CSV em que as colunas são separadas por ponto e vírgula “;”. Na imagem abaixo, são apresentadas as primeiras 5 linhas do arquivo, cada uma com um total de 10 colunas.

```
Afghanistan;2016;010410;Sheep, live;Export;6088;2339;Number of items;51;01_live_animals
Afghanistan;2016;010420;Goats, live;Export;3958;984;Number of items;53;01_live_animals
Afghanistan;2008;010210;Bovine animals, live pure-bred breeding;Import;1026804;272;Number of items;3769;01_live_animals
Albania;2016;010290;Bovine animals, live, except pure-bred breeding;Import;2414533;1114023;Number of items;6853;01_live_animals
Albania;2016;010392;Swine, live except pure-bred breeding > 50 kg;Import;14265937;9484953;Number of items;96040;01_live_animals
```

De acordo com o contexto apresentado acima, você e sua equipe são responsáveis por desenvolver soluções em Spark capazes de responder as seguintes perguntas:

1. **(0,5 ponto)** Número de transações envolvendo o Brasil através de RDD. O retorno deverá ser um único valor.
2. **(1,0 ponto)** Número de transações envolvendo o Brasil utilizando PairRDD. O retorno deverá ser composto de chave (Brasil) e valor.
3. **(0,5 ponto)** Número de transações envolvendo o Brasil durante 2016 utilizando RDD. O retorno deverá ser um único valor.
4. **(1,0 ponto)** Número de transações envolvendo o Brasil durante 2016 utilizando PairRDD. O retorno deverá ser com chave (Brasil, 2016) e valor.
5. **(1,0 ponto)** Número de transações por flow e por ano ordenados por ano a partir de 2010, transformando os valores da coluna Flow em maiúsculas. O retorno será em chave (ano, flow) e valor.
6. **(0,5 ponto)** A média da coluna Price para o ano de 2016 utilizando RDD. O retorno deverá conter apenas o valor da média.
7. **(1,0 ponto)** A média da coluna Price para o ano de 2016 utilizando PairRDD. O retorno deverá conter chave (ano) e valor.
8. **(1,0 ponto)** O preço máximo e mínimo por categoria e por ano, ordenado por país, sendo que a coluna categoria deve conter valores com letra maiúsculas. Utilizar PairRDD e a saída esperada deve conter: chave (ano, categoria) e valor (máximo, mínimo).

9. **(1,5 ponto)** Retornar um único valor para PairRDD contendo o país com a maior exportação (Flow=Export). A saída esperada é chave(país, flow) e valor.
10. **(1,0 ponto)** Buscar o preço mínimo por país e por ano, filtrado de forma crescente por ano e país (ordem alfabética).
11. **(1,0 ponto)** Transação que teve o maior preço por kg do tipo export. Buscar essa informação e indicar em qual ano, país e categoria, ela aconteceu?

Para cada um dos itens acima, forneça:

1. Será necessário retirar o cabeçalho.
2. Será necessário tratar dados faltantes.
3. Código fonte para a resolução do problema utilizando Spark em Python.
4. O resultado da execução em um arquivo separado e no formato txt.

OBS: Subam o arquivo completo no google drive. A subida parcial irá gerar resultados parciais e logo respostas incorretas.